GRANT DATA

ค้นหาทุนให้เปล่าสำหรับโปรเจกต์พร้อมภาระรายงาน จากแหล่งทางการ

NFR และความปลอดภัย

รหัสเอกสาร	BGD-DOC-03
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. สรุป

2. เป้าหมาย NFR ที่วัดได้

3. Performance และ scalability

4. Licensing / ToS ของแหล่ง

5. Security controls

6. Privacy / PDPA

7. Observability

8. Backup / DR

การอนุมัติ

แหล่งข้อมูล

Book Grant Data — NFR และความปลอดภัย

1. สรุป

ระบบเป็น local pilot ที่ไม่มี service ออนไลน์ NFR จึงเน้นความสดของข้อมูล คุณภาพข้อมูล การเคารพเงื่อนไขของแหล่ง และการไม่เก็บข้อมูลส่วนบุคคล ตัวเลขที่ "บังคับใช้แล้ว" มาจากโค้ด ส่วนเป้าหมายที่ยังไม่ได้บังคับใช้ระบุสถานะไว้ชัด

2. เป้าหมาย NFR ที่วัดได้

ID	หมวด	ข้อกำหนด	ค่าเป้าหมาย	สถานะ / หลักฐาน
NFR-01	Freshness	`--open-only` ตัด record ที่ตรวจเก่ากว่ากำหนด	72 ชั่วโมง (ค่า default `max_age_hours`)	บังคับใช้ใน `cli.py` `filter_items`
NFR-02	Freshness	ทบทวนแหล่งทุก 24 ชั่วโมง	24h	เป้าหมายใน `PRODUCT.md`; ยังไม่มี schedule
NFR-03	Freshness SLO	parent monitor รายงาน fresh/stale/quarantined ต่อแหล่ง	7/7 แหล่ง	ยังไม่ทำ (`grt-g2`)
NFR-04	Source load	ช่วงห่างขั้นต่ำต่อแหล่ง	21,600 วินาที (6 ชม.) ใน `min_interval_seconds` ทุกแหล่ง	บังคับใช้โดย shared runtime + file lock
NFR-05	Source load	จำนวนครั้ง/timeout/ขนาด	≤ 2 GET, 15 วินาทีต่อครั้ง, ≤ 2 MB	บังคับใช้ใน `capture_runtime.py`
NFR-06	Capacity	record ต่อ envelope	≤ 10,000	ระบุใน `PRODUCT.md`
NFR-07	Data quality	export ผ่าน JSON Schema และกฎเพิ่ม (ไม่รับ NaN/Infinity, ข้อความว่าง/มองไม่เห็น, id ซ้ำ, `live` ต้องมี lineage)	100% ของ record	บังคับใช้ใน `validate` + tests
NFR-08	Data quality	หน้าเปลี่ยน/challenge page ไม่ถูกรับเป็นข้อมูล	markers ครบทุกตัว มิฉะนั้น quarantine	บังคับใช้; markers ของ SBA ยังอ่อน (backlog P1)
NFR-09	Correctness	เวลาปิดรับแบบ UK แปลงเป็น UTC โดยไม่ขึ้นกับ locale	ครอบคลุม BST/GMT	tests ใน `tests/test_source.py`
NFR-10	Availability	ไม่มี SLA (ไม่มี service)	—	ระบุใน `PRODUCT.md` "no live SLA"
NFR-11	Portability	CLI contract รันได้โดยไม่มี parent	Python 3.10 และ 3.13	CI matrix

3. Performance และ scalability

- ข้อมูลระดับหลักสิบ record (7 แหล่ง × ~1 record ต่อแหล่งในปัจจุบัน) การกรองเป็น in-memory
- การขยายโดเมน/แหล่งทำได้โดยเพิ่ม `source-*.json` + adapter; ข้อจำกัดหลักคือ cooldown และงานตรวจสิทธิ์ ไม่ใช่ compute
- ไม่มีการวัด latency **[ต้องยืนยัน]** ว่าจำเป็นหรือไม่เมื่อมี consumer

4. Licensing / ToS ของแหล่ง

Source ID	การเข้าถึง	หลักฐานสิทธิ์ (permission_evidence)	ทบทวนล่าสุด
govuk-innovation-funding	GOV.UK Content API	นโยบาย reuse GOV.UK — Crown copyright, OGL v3.0	2026-09-07
depa-digital-startup-fund	HTML	อ้างเฉพาะ URL หน้าเว็บ ไม่มีเอกสารเงื่อนไข **[ต้องยืนยัน]**	2026-09-07
iuk-zevi2-alternative-fuels	HTML	อ้างเฉพาะ URL หน้าเว็บ **[ต้องยืนยัน]**	2026-09-07
grants-gov-research-opportunities	HTML	robots.txt	2026-09-08
creative-europe-culture-calls	HTML	robots.txt	2026-09-08
national-lottery-community-funding	HTML	robots.txt	2026-09-08
sba-small-business-grants	HTML	robots.txt	2026-09-08

หลักการ: ทุกแหล่งมี `permission_status: reviewed-public-read` และ `use` = metadata สำหรับ personal discovery, "no source-body republication" การ robots.txt อนุญาตไม่เท่ากับการอนุญาตให้ นำไปใช้เชิงพาณิชย์ — หากทำ digest ขาย (FR-11) ต้องทบทวน ToS ของแต่ละแหล่งก่อน **[ต้องยืนยัน]** แหล่ง NIA ถูกปิดจนกว่าจะมี API/export ทางการ

5. Security controls

- Network: HTTPS GET อ่านอย่างเดียว, ไม่ follow redirect โดยอัตโนมัติ (ต้องทบทวน policy), ไม่ retry เมื่อได้ 429/auth failure
- ไม่ใช้ credential, cookie หรือบัญชีผู้ใช้ใด ๆ; ปฏิเสธการ archive เมื่อพบ session-token marker
- Source ID selector ปฏิเสธ path traversal และ ID ที่ไม่รู้จัก (`tests/test_registry.py`)
- `validate` ไม่ echo เนื้อหา input ออกทาง error และไม่บันทึกไฟล์
- `.gitignore` กัน `data/` , `logs/` , `.env*` , `credentials/` ไม่ให้เข้า Git
- Supply chain: `jsonschema` และ `ruff` pin version; GitHub Actions ใช้ `permissions: contents: read`

6. Privacy / PDPA

- ข้อมูลเป็น metadata สาธารณะของโครงการทุนเท่านั้น ไม่มี profile ผู้ใช้ ใบสมัคร คำตอบคัดกรอง หรือข้อมูลการเงินส่วนบุคคล
- การตัดสินคุณสมบัติส่วนบุคคลเป็นหน้าที่ของ consumer ที่มี private storage แยก (README)
- หน้าเว็บต้นฉบับอาจมีชื่อ/อีเมลผู้ติดต่อของหน่วยงาน — bytes ดิบเก็บใน private local archive เท่านั้นและไม่ถูกดึงเป็น field **[สมมติฐาน]** ควรยืนยันว่าไม่มีข้อมูลบุคคลหลุดเข้า Bronze metadata
- Retention: "private local raw archive; operational retention; no automatic deletion" — ยังไม่มีกำหนดระยะเก็บเป็นตัวเลข **[ต้องยืนยัน]**

7. Observability

- ปัจจุบัน: control state ต่อแหล่ง (เวลาตรวจ, quarantine) และ exit code ของคำสั่ง

- ยังไม่มี: log rotation, alert, dashboard; parent coverage registry ยังไม่รวม grant (`observed_gaps` ใน roadmap)
- เป้าหมาย: log ของ schedule มีเฉพาะจำนวนสถานะต่อแหล่ง ไม่มี payload (`grt-t3`)

8. Backup / DR

- โค้ด/contract/source policy: อยู่ใน Git remote
- `data/lake` และ `data/control`: อยู่บนเครื่อง operator เท่านั้น ไม่มี backup ที่บันทึกไว้ **[ต้องยืนยัน]**
- DR: เนื่องจากแหล่งเป็นสาธารณะ การสูญเสีย lake กู้ได้ด้วยการ acquire ใหม่ แต่จะเสีย history ของ bytes เดิม

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Solution Architect (Book Dev)	รอพิจารณา	—	_
Security reviewer	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `PRODUCT.md`
- `sources.json`
- `src/book_grant_data/source.json`, `src/book_grant_data/source-*.json`
- `src/book_grant_data/cli.py`
- `tests/test_registry.py`
- `.gitignore`
- `.github/workflows/ci.yml`
- `docs/UPGRADE-PLAN.md`
- `(solo-empire) infra/scripts/discovery/capture_runtime.py`
- `(solo-empire) repository-catalog/roadmaps/data-scrapers.yaml`